

Nowcasting de Relâmpagos com Aprendizado de Máquina para o Sul/Sudeste da América do Sul

L. Pavam^{*,1,2}, C. Beneti¹, L. Oliveira², M. Zanata²

¹SIMEPAR, Curitiba/PR, Brasil

²Departamento de Informática, UFPR, Curitiba/PR, Brasil

*luispavam@gmail.com

RESUMO

Informações e previsões sobre variáveis atmosféricas são essenciais para a sociedade contemporânea. Eventos meteorológicos de alto impacto, como tempestades e relâmpagos, afetam diversos setores e demandam atitudes preventivas para redução de seus efeitos danosos. O presente texto apresenta o desenvolvimento de um modelo predictor de curtíssimo prazo da ocorrência de relâmpagos com foco em descargas do tipo nuvem-solo, empregando dados de redes de detecção e localização de relâmpagos, satélite e radares meteorológicos, com base em métodos de aprendizado de máquina. O relâmpago consiste em uma descarga elétrica transiente de elevada tensão e intensa corrente elétrica, responsável por gerar, depositar e redistribuir vastas quantias de carga em uma tempestade. O aprendizado de máquina se baseia em grandes conjuntos de dados para treinamento do modelo, de forma que primariamente construiu-se uma base de dados contendo as ocorrências de relâmpagos identificadas pelas redes de detecção e localização de relâmpagos presentes na região de interesse do estudo, entre 2018 a 2022, além de dados de satélite para identificação de nuvens convectivas. Diferentes métodos de aprendizado de máquina são testados, e a escolha do algoritmo é feita por meio da análise de métricas de desempenho. Posteriormente, é realizada a avaliação do modelo e, sendo verificado um desempenho satisfatório, este será operacionalizado para uso em cenários reais. A previsão a curtíssimo prazo de relâmpagos confiável e com suficiente antecedência permite a proteção de importantes ativos de indústrias e de vidas, evitando prejuízos e reduzindo os riscos a segurança da população decorrentes da presença de descargas elétricas atmosféricas.

Palavras-Chave: Nowcasting, Aprendizado de Máquina, Relâmpagos, Satélite, Sensoriamento Remoto.

1 Introdução

A previsão de tempestades e relâmpagos é essencial para a segurança da população e para o funcionamento das indústrias. Os relâmpagos constituem um dos principais perigos decorrentes das tempestades, sendo responsáveis por milhares de mortes e bilhões de dólares em prejuízos anuais em todo o mundo [7].

O relâmpago é uma descarga elétrica transiente de elevada tensão e intensa corrente elétrica, sendo um fenômeno atmosférico de curta duração e rápida evolução. Este fenômeno ocorre na atmosfera quando o campo elétrico ultrapassa localmente o isolamento dielétrico do ar, causando um estresse elétrico entre duas regiões de cargas opostas tão grande que ocorre o colapso dielétrico e dá-se início a um relâmpago [1].

Os relâmpagos são responsáveis por gerar, depositar e redistribuir vastas quantias de carga elétrica em uma tempestade, agindo primariamente para reduzir a energia elétrica desses sistemas, transportando corrente

elétrica negativa das regiões mais altas da atmosfera para a superfície terrestre [4]. Os relâmpagos são classificadas de acordo com a localização dos centros de carga, havendo as descargas nuvem-solo (NS), entre-nuvens (NN), intra-nuvens (IN) e nuvem-ar (NA) [10].

A previsão deste evento dinâmico é feita a curtíssimo prazo, definindo uma atividade de nowcasting. O nowcasting é motivado pela necessidade de se prever fenômenos de alto impacto para locais específicos com suficiente antecedência [2], sendo definido como a previsão com detalhamento local, por qualquer método, em um intervalo de tempo de até seis horas no futuro, incluindo uma descrição detalhada das condições atmosféricas vigentes [9].

Os avanços tecnológicos das últimas décadas (e.g., aumento da capacidade de processamento dos computadores, redução nos custos de armazenamento de dados e melhor performance no gerenciamento de vastas quantias de dados) possibilitaram a difusão de técnicas como o Aprendizado de Máquina (AM) para além da ciência da computação.

O AM é útil às análises meteorológicas por sua capacidade de derivar informações e identificar padrões em grandes conjuntos de dados, fornecendo ferramentas para o desenvolvimento de modelos de análise ou previsão. Além disso, sistemas automáticos são ideais para o nowcasting, devido ao curto período de tempo associado a esta forma de previsão.

Este trabalho descreve o desenvolvimento de um modelo baseado em AM para o nowcasting de relâmpagos em uma região de interesse (ROI). O foco da pesquisa é a melhoria da previsão de relâmpagos nuvem-solo (NS) a curtíssimo prazo para o Sul/Sudeste da América do Sul (SSESA), por meio da busca de algoritmos adequados para a tarefa, considerando os dados disponíveis.

2 Metodologia

A análise, monitoramento e previsão dos relâmpagos é possível por meio do uso de diferentes sistemas de sensores in-situ e remotos, como as redes de detecção e localização de relâmpagos (RDLR), satélites com instrumentos de observação atmosférica e radares. Todas as formas de descargas elétricas atmosféricas são associadas ao deslocamento de cargas e, portanto, podem ser analisadas por meio da medição dos campos elétricos e magnéticos relacionados ao movimento das cargas [10].

Este trabalho considera dados de diversas RDLR presentes no SSESA, assim como dados do satélite GOES16 – ambos sistemas que monitoram continuamente a região, fornecendo dados temporais e espaciais de alta resolução sobre relâmpagos. Espera-se que o uso de dados de múltiplas fontes aumente a confiabilidade das previsões.

As RDLR fornecem os seguintes dados sobre relâmpagos na ROI, de 2018 a 2022: data (ano, mês, dia); hora (hora, minuto, segundo, nanossegundo); coordenadas espaciais (latitude e longitude); pico de corrente; polaridade (positiva ou negativa); multiplicidade (quantidade de descargas de retorno em um relâmpago); e indicador do tipo de evento (NS ou IN). Os dados do satélite GOES16 são usados para monitorar as nuvens convectivas, fornecendo informações sobre a profundidade temperatura de topo da nuvem – elementos importantes no processo de eletrificação da nuvem. Estas variáveis foram escolhidas por seu valor na descrição e previsão da ocorrência de eventos relâmpagos.

Os dados das RDLR e do satélite são usados tanto para treinamento quanto para a entrada do modelo – relâmpagos IN normalmente precedem descargas NS, sendo um elemento preditivo para relâmpagos NS. O modelo é treinado para identificar e categorizar de acordo com sua relevância as variáveis mais associadas à geração de raios, permitindo assim a identificação de fatores preditivos.

A proposta deste trabalho define uma tarefa de regressão para o modelo de AM. Diferentes algoritmos

adequados para problemas de regressão são testados com o objetivo de identificar o algoritmo mais adequado para a tarefa estabelecida. Estes algoritmos são avaliados de acordo com métricas de desempenho utilizadas para a análise, comparação e subsequente definição do algoritmo a ser implementado no modelo.

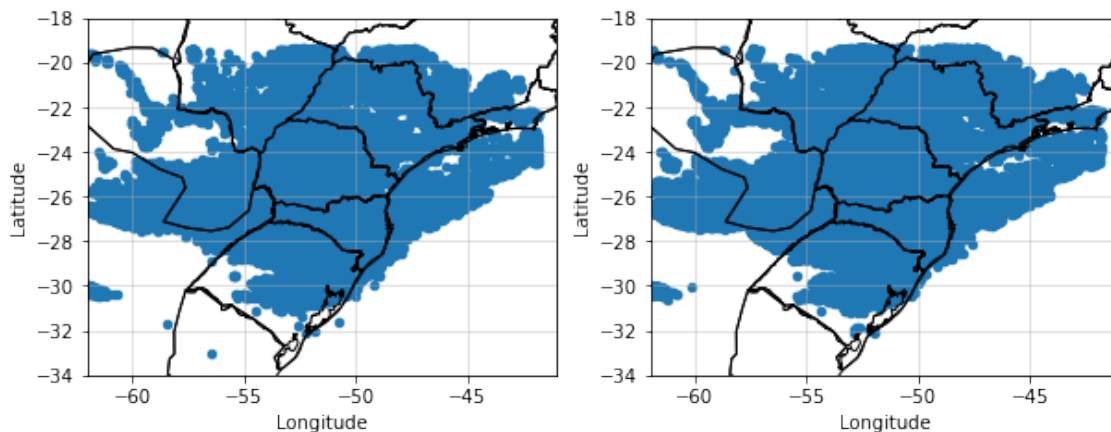
3 Resultados e Discussão

O nowcasting de relâmpagos no SSESa atualmente é feito por meio de métodos estatísticos, sendo a magnitude da convecção uma das principais variáveis consideradas nesta previsão [5]. O uso de AM na previsão a curtíssimo prazo tem o prospecto de melhorar a qualidade da previsão e o tempo de antecedência desta [3].

O modelo deverá ter uma performance equivalente ou até superior a de um previsor humano, mas com a vantagem de ser mais consistente e, até um certo grau, mais explícito, lidando com uma variedade de problemas e, tendo dados suficientes, ser altamente genérico, para ser usado em situações práticas com sucesso [8].

As RDLRs se baseiam em diferentes parâmetros para declarar a presença de relâmpagos, além de variarem em características como quantia e distribuição dos sensores. O uso de múltiplas RDLRs garante que uma quantidade suficiente de relâmpagos é capturada e que esses eventos correspondem com a realidade. A Figura 1 apresenta a ROI, denotando eventos de relâmpago IN e NS capturados por uma RLDR no SSESa.

Figura 1: Eventos de relâmpagos NS (esquerda) e IN (direita) em 10/01/2021 no SSESa.



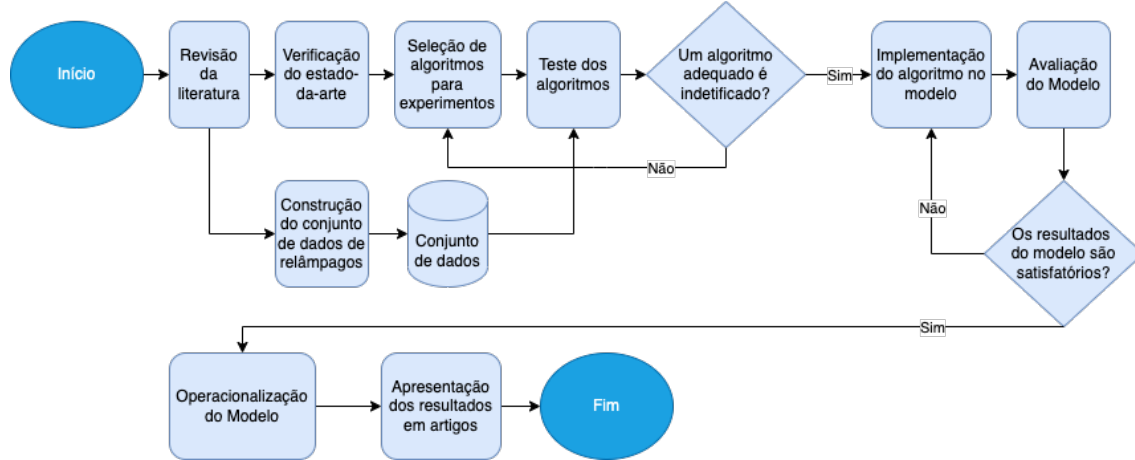
Fonte: Autor.

A ROI neste estudo é definida como a região SSESa, não só por abranger grandes centros populacionais e econômicos, mas também por abrigar a segunda maior usina hidrelétrica do mundo, Itaipu. As linhas de transmissão de energia nesta região representam um importante ativo no sistema de distribuição de energia do continente, sendo particularmente dependentes da previsão de relâmpagos NS, que são uma das principais causas relacionadas à eventos de quedas de energia [5].

A Figura 2 apresenta as etapas para o desenvolvimento deste trabalho, denotando como será feito o desenvolvimento do modelo. Com base no conjunto de treinamento contendo dados sobre relâmpagos no SSESa, será utilizado AM para regressão – o modelo será treinado para identificar e categorizar de acordo com a sua influência as variáveis das tempestades associadas à geração de relâmpagos, de modo a permitir a identificação de elementos preditores [6].

Dessa forma, ter-se-á um modelo apto a identificar padrões em um conjunto de dados, possibilitando que o modelo reconheça padrões de evolução das nuvens e declare a presença de convecção. O algoritmo deverá

Figura 2: Fluxograma do desenvolvimento do modelo predictor de relâmpagos.



Fonte: Autor.

identificar as características morfológicas das tempestades mais relevantes para a ocorrência de relâmpagos e assim ser capaz de prever a ocorrência de relâmpagos.

Qualquer modelo é um objeto matemático feito para reproduzir determinados aspectos dos processos físicos envolvidos nas descargas elétricas, sendo uma etapa essencial da modelagem a validação, na qual eventos reais declarados pelas RDLR e o satélite GOES16 serão confrontados com as previsões do modelo. Dessa forma, é possível observar como o algoritmo se comporta e seu nível de sucesso. A escolha do algoritmo será feita considerando as métricas de performance, demanda de recursos computacionais e tempo de treinamento.

O modelo será avaliado e, sendo aprovado, será utilizado para fins operacionais, auxiliando os meteorologistas na tarefa de notificar as partes interessadas sobre a ocorrência de relâmpagos. Estando o modelo operacional, fontes adicionais de dados serão incluídas para melhorar a previsão.

O radar é um instrumento capaz de observar diretamente um sistema meteorológico em três dimensões sobre uma ampla área com uma rápida taxa de atualização, sendo uma ferramenta valiosa para o nowcasting [9]. Este instrumento é capaz de fornecer informações sobre a composição e a estrutura vertical de um sistema atmosférico, indicando o desenvolvimento de zonas eletricamente carregadas na nuvem. Este também será um importante instrumento a ser considerado no modelo de previsão usando AM.

4 Conclusão

Este trabalho apresenta resultados preliminares da pesquisa, introduzindo os dados e algoritmos de AM aptos a desenvolver um modelo de nowcasting de relâmpagos baseado em dados de múltiplas fontes, tendo como objetivo a construção de um modelo preditivo que irá superar o método atualmente utilizado.

Uma previsão precisa de relâmpagos com tempo de antecedência satisfatório mitiga a perda econômica e de vidas, causadas por este fenômeno atmosférico. A intenção deste trabalho é aumentar o tempo de antecedência das previsões de relâmpagos com o desenvolvimento do modelo, prevendo relâmpagos para até três horas no futuro.

Ao final desta pesquisa, um modelo para nowcasting de relâmpagos terá sido construído para uso operacional no SSES. O produto do modelo é a data, hora, localização, probabilidade e características dos eventos de relâmpago nas próximas horas para a ROI. Além da previsão do evento em si, este trabalho visa prever

características importantes deste fenômeno, tais como corrente de pico, polaridade e tipo de relâmpago (NS ou IN).

5 Agradecimentos

Agradecimentos ao Sistema de Tecnologia e Monitoramento Ambiental do Paraná (SIMEPAR) e ao laboratório High Performance and Efficient Systems (HiPES) da Universidade Federal do Paraná pelo apoio científico e suporte material na condução desta pesquisa.

Referências

- [1] C. A. A. Beneti. “Caracterização Hidrodinâmica e Elétrica de Sistemas Convectivos de Mesoescala”. Tese de dout. São Paulo - SP: Universidade de São Paulo - Instituto de Astronomia, Geofísica e Ciências Atmosféricas, 2012.
- [2] K. A. Browning e G. A. Monk. “A Simple Model for the Synoptic Analysis of Cold Fronts”. Em: *Quarterly Journal of the Royal Meteorological Society* 108.456 (1982), pp. 435–452. DOI: <https://doi.org/10.1002/qj.49710845609>.
- [3] S. E. Haupt et al. “The History and Practice of AI in the Environmental Sciences”. Em: *Bulletin of the American Meteorological Society* 103.5 (2022), E1351–E1370. DOI: [10.1175/BAMS-D-20-0234.1](https://doi.org/10.1175/BAMS-D-20-0234.1).
- [4] P. R. Krehbiel. “The Earth’s Electrical Environment”. Em: National Academy Press, 1986, pp. 90–113.
- [5] E. A. Leite, A. Y. Igarashi e M. A. Jusevicius. “Sistema de Previsão Probabilística Espacial de Eventos de Descargas Atmosféricas e sua Aplicação na Vigilância Meteorológica do Sistema Elétrico”. Em: *XIX Seminário Nacional de Produção e Transmissão de Energia Elétrica* (2011).
- [6] Amy McGovern et al. “Using Artificial Intelligence to Improve Real-Time Decision-Making for High-Impact Weather”. Em: *Bulletin of the American Meteorological Society* 98.10 (Outubro de 2017), pp. 2073–2090.
- [7] METED. *GOES-R GLM: Introduction to the Geostationary Lightning Mapper*. https://www.meted.ucar.edu/goes_r/glm. Acesso em 08/09/2022. 2014.
- [8] D. Michie, D.J. Spiegelhalter e C. C Taylor. *Machine Learning, Neural and Statistical Classification*. Ellis Horwood, 1994.
- [9] Organização Meteorológica Mundial. *Guidelines for Nowcasting*. Chairperson, Publications Board, 2017.
- [10] V. A. Rakov. *Fundamentals of Lightning*. Cambridge University Press, 2016.